Taller: Limpieza y Preparación de Datos con Python (pandas)

Objetivo del taller

Aplicar técnicas fundamentales de **limpieza, transformación y preparación de datos** utilizando la librería **pandas** en Python, a partir de un conjunto de datos reales con inconsistencias, valores faltantes y errores comunes.

El propósito del taller **no es la cantidad de datos**, sino **identificar y corregir problemas reales de calidad de datos**, tal como ocurre en proyectos profesionales de análisis de datos y aprendizaje automático.

Descripción del dataset

El archivo **datos_para_limpiar.csv** contiene información de empleados con las siguientes características:

- Valores nulos en múltiples columnas
- Errores de escritura y formatos inconsistentes
- Datos fuera de rangos válidos
- Variables numéricas, categóricas y ordinales
- Fechas y valores monetarios

El dataset contiene **100 registros**, tamaño elegido intencionalmente para facilitar la comprensión, revisión y análisis detallado de cada transformación.

Instrucciones del ejercicio

1. Exploración inicial del dataset

1. Carga el archivo **datos_para_limpiar.csv** utilizando **pandas**.

2. Muestra:
    - Las primeras **5 filas** del dataset.
    - La información general del DataFrame (tipos de datos).
    - El conteo de **valores nulos por columna**.

---

2 Eliminación de columnas innecesarias

Elimina las siguientes columnas del dataset:

- ID
- Notas

Estas columnas no aportan valor analítico para los procesos posteriores.

---

3 Normalización de nombres de columnas

Renombra **todas las columnas** para que:

- Estén en **minúsculas**.
- No contengan **espacios**.
- No contengan **tildes**.

A partir de este punto, utiliza exclusivamente los nuevos nombres de las columnas en el resto del ejercicio.

---

4 Corrección de errores de escritura

Unifica los valores de la columna **ciudad** para que utilicen un formato consistente para las siguientes ciudades:

- **Bogotá**
- **Medellín**
- **Cali**

Elimina espacios adicionales y corrige diferencias de mayúsculas, minúsculas y tildes.

---

5 Tratamiento de valores nulos

Realiza el manejo de valores faltantes según las siguientes reglas:

- En la columna **edad**, reemplaza los valores nulos por la **media**, calculada únicamente con edades válidas (entre 0 y 120 años).
- En la columna **salario**, reemplaza los valores nulos por la **mediana**.
- En las columnas **ciudad** y **genero**, reemplaza los valores nulos por la **moda**.

---

6 Asegurar tipos de datos correctos

- Convierte la columna **edad** a tipo numérico.
- Convierte la columna **fecha** a formato de fecha (**datetime**).

---

7 Filtrado de datos fuera de rango

Elimina del dataset:

- Registros con edades fuera del rango **0–120 años**.
- Registros con salarios mayores a **1.000 millones**.

---

8 Conversión de variables ordinales

Convierte la columna **nivel** a valores numéricos según la siguiente escala:

- bajo ⟶ 1
- medio ⟶ 2
- alto ⟶ 3

Los valores no definidos (**n/a** o vacíos) deben mantenerse como valores nulos.

---

9 Codificación de variables categóricas

Convierte las variables categóricas **genero** y **ciudad** a variables numéricas utilizando **pd.get_dummies**, eliminando la primera categoría para evitar multicolinealidad.

---

10 Escalado de variables numéricas

Escala las columnas **edad** e **ingresos** a un rango entre **0 y 1**, utilizando **MinMaxScaler**.

---

11 Eliminación de registros duplicados

Elimina las filas duplicadas que existan en el dataset.

12Creación de nuevas variables

Agrega una nueva columna llamada **utilidad**, calculada como:

utilidad = ingresos - gastos

---

13 Guardado del dataset limpio

Exporta el DataFrame final a un archivo llamado:

datos_limpios.csv

Entregable

- Archivo **datos_limpios.csv**
- script en Python con el código utilizado
- Comentarios claros que expliquen cada paso del proceso